

# Génération augmentée par des connaissances médicales

Des résultats préliminaires grâce à *Med-KAG*

---

Edouard Haddag, Gabriel Medeiros et Lina F. Soualmia

25 janvier 2026

Université de Rouen Normandie

INSA Rouen Normandie

Laboratoire d'Informatique, du Traitement de l'Information et des Systèmes (LITIS)



1. La problématique et les objectifs
2. Méthodes
3. Résultats
4. Discussion & Conclusion

## La problématique et les objectifs

---

L'intégration de l'IA en pratique clinique offre un potentiel pour l'analyse des dossiers médicaux [1, 10].

# Problématique : Les limites des LLM en clinique

L'intégration de l'IA en pratique clinique offre un potentiel pour l'analyse des dossiers médicaux [1, 10].

- **Opacité** : Difficulté à tracer l'origine.

# Problématique : Les limites des LLM en clinique

L'intégration de l'IA en pratique clinique offre un potentiel pour l'analyse des dossiers médicaux [1, 10].

- **Opacité** : Difficulté à tracer l'origine.
- **Hallucinations** : Risque de génération de données médicales erronées ou non vérifiées [5].

# Problématique : Les limites des LLM en clinique

L'intégration de l'IA en pratique clinique offre un potentiel pour l'analyse des dossiers médicaux [1, 10].

- **Opacité** : Difficulté à tracer l'origine.
- **Hallucinations** : Risque de génération de données médicales erronées ou non vérifiées [5].
- **Limites du RAG classique** : Le RAG classique [3] repose sur du texte non structuré, ce qui peut manquer de précision relationnelle.

Med-KAG<sup>1</sup> propose de passer d'un RAG classique à une architecture de **Knowledge Augmented Generation (KAG)**.

---

1. <https://github.com/c2fc2f/Med-KAG>



Med-KAG<sup>1</sup> propose de passer d'un RAG classique à une architecture de **Knowledge Augmented Generation (KAG)**.

Les deux objectifs principaux :

1. **Minimiser les hallucinations** : Contraindre les réponses du modèle par des données factuelles issues d'une base structurée.

---

1. <https://github.com/c2fc2f/Med-KAG>

Med-KAG<sup>1</sup> propose de passer d'un RAG classique à une architecture de **Knowledge Augmented Generation (KAG)**.

Les deux objectifs principaux :

1. **Minimiser les hallucinations** : Contraindre les réponses du modèle par des données factuelles issues d'une base structurée.
2. **Fournir une justification** : Rendre le système transparent en traçant l'origine du raisonnement via des connexions vérifiables.

---

1. <https://github.com/c2fc2f/Med-KAG>

# Méthodes

---

# L'approche Knowledge Augmented Generation (KAG)

Med-KAG se distingue du RAG classique par l'utilisation de connaissances structurées :

# L'approche Knowledge Augmented Generation (KAG)

Med-KAG se distingue du RAG classique par l'utilisation de connaissances structurées :

- **Substitution du texte** : Les documents non structurés sont remplacée par l'exploitation d'un graphe de connaissances (Knowledge Graph) [4].

# L'approche Knowledge Augmented Generation (KAG)

Med-KAG se distingue du RAG classique par l'utilisation de connaissances structurées :

- **Substitution du texte** : Les documents non structurés sont remplacée par l'exploitation d'un graphe de connaissances (Knowledge Graph) [4].
- **Ancrage sémantique** : Utilisation du *Métathésaurus* de l'*UMLS* [2] comme source de vérité structurée

# L'approche Knowledge Augmented Generation (KAG)

Med-KAG se distingue du RAG classique par l'utilisation de connaissances structurées :

- **Substitution du texte** : Les documents non structurés sont remplacée par l'exploitation d'un graphe de connaissances (Knowledge Graph) [4].
- **Ancrage sémantique** : Utilisation du *Métathésaurus* de l'*UMLS* [2] comme source de vérité structurée
- **Conception modulaire** : Une architecture linéaire conçue pour évoluer vers des flux complexes d'auto-correction.

# Architecture du système Med-KAG




Figure 1 : Schéma de l'architecture de Med-KAG

- **Récupérateur (LLM)** : Identifie les entités et génère une requête *Cypher*.
- **Extraction (KG)** : Interroge le graphe pour extraire un sous-graphe (Sub-KG) pertinent.
- **Générateur (Qwen3)** : Verbalise le contexte structuré pour produire la réponse finale.



Le module de récupération transforme la question de l'utilisateur en un langage formel pour interroger le graphe :

Le module de récupération transforme la question de l'utilisateur en un langage formel pour interroger le graphe :

- **Base UMLS** : Utilisation d'un KG médical structuré, issu de travaux précédents [6].

Le module de récupération transforme la question de l'utilisateur en un langage formel pour interroger le graphe :

- **Base UMLS** : Utilisation d'un KG médical structuré, issu de travaux précédents [6].
- **Requêtes Cypher** : Le LLM (*Qwen3-235B* [9]) agit comme traducteur vers le langage *Cypher* (*Neo4j*) [7].

Le module de récupération transforme la question de l'utilisateur en un langage formel pour interroger le graphe :

- **Base UMLS** : Utilisation d'un KG médical structuré, issu de travaux précédents [6].
- **Requêtes Cypher** : Le LLM (*Qwen3-235B* [9]) agit comme traducteur vers le langage *Cypher* (*Neo4j*) [7].
- **Transparence** : Chaque réponse peut être justifiée par l'extraction du voisinage sémantique des entités.

## Résultats

---

## Évaluation sur le dataset *MedQA-US (MIRAGE)* [8]

| Modèle                     | Réponses correctes | Taux de précision |
|----------------------------|--------------------|-------------------|
| Native (Qwen3-235B-A22B)   | 1167/1273          | 91,67%            |
| RAG (Qwen3-235B-A22B + KG) | 1162/1273          | 91,28%            |

**Table 1 :** Précision comparative sur *MedQA-US*.

## Évaluation sur le dataset *MedQA-US (MIRAGE)* [8]

| Modèle                     | Réponses correctes | Taux de précision |
|----------------------------|--------------------|-------------------|
| Native (Qwen3-235B-A22B)   | 1167/1273          | 91,67%            |
| RAG (Qwen3-235B-A22B + KG) | 1162/1273          | 91,28%            |

**Table 1 :** Précision comparative sur *MedQA-US*.

| Métrique                   | Moyenne | Médiane | Non nulle        |
|----------------------------|---------|---------|------------------|
| Erreurs (Requête invalide) | 0,22    | 0,00    | —                |
| Nœuds récupérés            | 23,92   | 0,00    | 502/1273 (39,4%) |
| Arêtes récupérées          | 27,92   | 0,00    | 254/1273 (20,0%) |

**Table 2 :** Mesures de récupération (moyenne, médiane et non nulle).

## Discussion & Conclusion

---



## Discussion : Vers un récupérateur hybride

Pour dépasser le goulot d'étranglement de la récupération :

## Discussion : Vers un récupérateur hybride

Pour dépasser le goulot d'étranglement de la récupération :

- Stratégie Hybride :

## Discussion : Vers un récupérateur hybride

Pour dépasser le goulot d'étranglement de la récupération :

- **Stratégie Hybride :**

1. Recherche vectorielle pour identifier des nœuds « graines ».

# Discussion : Vers un récupérateur hybride

Pour dépasser le goulot d'étranglement de la récupération :

- **Stratégie Hybride :**

1. Recherche vectorielle pour identifier des nœuds « graines ».
2. Construction guidée par LLM de la logique de traversée du graphe.

# Discussion : Vers un récupérateur hybride

Pour dépasser le goulot d'étranglement de la récupération :

- **Stratégie Hybride :**
  1. Recherche vectorielle pour identifier des nœuds « graines ».
  2. Construction guidée par LLM de la logique de traversée du graphe.
- **Avantage :** Se concentrer sur le raisonnement relationnel plutôt que sur la syntaxe de la requête.

*Med-KAG* confirme la faisabilité de l'ancrage d'un système RAG dans un graphe de connaissances médicales.

*Med-KAG* confirme la faisabilité de l'ancrage d'un système RAG dans un graphe de connaissances médicales.

- **Constat** : L'implémentation actuelle est perfectible mais identifie clairement les verrous technologiques.

*Med-KAG* confirme la faisabilité de l'ancrage d'un système RAG dans un graphe de connaissances médicales.

- **Constat** : L'implémentation actuelle est perfectible mais identifie clairement les verrous technologiques.
- **Travaux futurs** :



*Med-KAG* confirme la faisabilité de l'ancrage d'un système RAG dans un graphe de connaissances médicales.

- **Constat :** L'implémentation actuelle est perfectible mais identifie clairement les verrous technologiques.
- **Travaux futurs :**
  - Développement d'un récupérateur hybride (en cours).

*Med-KAG* confirme la faisabilité de l'ancrage d'un système RAG dans un graphe de connaissances médicales.

- **Constat** : L'implémentation actuelle est perfectible mais identifie clairement les verrous technologiques.
- **Travaux futurs** :
  - Développement d'un récupérateur hybride (en cours).
  - Tester la pertinence des réponses avec des experts du milieu pour évaluer l'utilité réelle en aide à la décision

*Med-KAG* confirme la faisabilité de l'ancrage d'un système RAG dans un graphe de connaissances médicales.


- **Constat :** L'implémentation actuelle est perfectible mais identifie clairement les verrous technologiques.
- **Travaux futurs :**
  - Développement d'un récupérateur hybride (en cours).
  - Tester la pertinence des réponses avec des experts du milieu pour évaluer l'utilité réelle en aide à la décision
  - Amélioration de l'explicabilité pour les cliniciens.

Merci de nous avoir écouté.  
Des questions ?

# Exemple de requête et de graphe

Requête Cypher générée :

```
MATCH (c1:CUI)
WHERE c1.name CONTAINS "flexor tendon"
OPTIONAL MATCH (c1)-[r1:PAR|CHD|SY|RO]->(c2:CUI)
OPTIONAL MATCH (c2)-[r2:PAR|CHD|SY|RO]->(c3:CUI)
RETURN c1, c2, c3, r1, r2
LIMIT 250
```



**Figure 2 :** À gauche, la requête Cypher générée par le LLM; à droite, le sous-graphe UMLS récupéré servant de contexte ancré pour la réponse.

## Exemple de question et de réponse

**Question :** *A junior orthopaedic surgery resident is completing a carpal tunnel repair with the department chairman as the attending physician. During the case, the resident inadvertently cuts a flexor tendon. The tendon is repaired without complication. The attending tells the resident that the patient will do fine, and there is no need to report this minor complication that will not harm the patient, as he does not want to make the patient worry unnecessarily. He tells the resident to leave this complication out of the operative report. Which of the following is the correct next action for the resident to take?*

**Options :**

- *(A) Disclose the error to the patient and put it in the operative report.*
- *(B) Tell the attending that he cannot fail to disclose this mistake.*
- *(C) Report the physician to the ethics committee.*
- *(D) Refuse to dictate the operative report.*

**Med-KAG Answer :** *B*

-  H. Alghamdi and A. Mostafa.  
**Advancing ehr analysis : Predictive medication modeling using llms.**  
*Information Systems*, 131:102528, 2025.
-  O. Bodenreider.  
**The Unified Medical Language System (UMLS) : integrating biomedical terminology.**  
*Nucleic Acids Research*, 32(Database issue):D267–D270, Jan 2004.
-  Y. Gao, Y. Xiong, M. Wang, and H. Wang.  
**Modular rag : Transforming rag systems into lego-like reconfigurable frameworks,**  
2024.

-  A. Hogan, E. Blomqvist, M. Cochez, C. D'amato, G. D. Melo, C. Gutierrez, S. Kirrane, J. E. L. Gayo, R. Navigli, S. Neumaier, A.-C. N. Ngomo, A. Polleres, S. M. Rashid, A. Rula, L. Schmelzeisen, J. Sequeda, S. Staab, and A. Zimmermann.

**Knowledge graphs.**

*ACM Comput. Surv.*, 54(4), July 2021.

-  L. Huang, W. Yu, W. Ma, W. Zhong, Z. Feng, H. Wang, Q. Chen, W. Peng, X. Feng, B. Qin, and T. Liu.

**A survey on hallucination in large language models : Principles, taxonomy, challenges, and open questions.**

*ACM Trans. Inf. Syst.*, 43(2), Jan. 2025.



-  G. H. A. Medeiros, L. F. Soualmia, and C. Zanni-Merk.  
**Harnessing the core propagation phenomenon ontology to develop a knowledge graph for tracking health-related phenomena.**  
*Studies in Health Technology and Informatics*, 316:1933–1937, Aug 2024.
-  Neo4j.  
**Neo4j cypher manual : Overview, 2025.**
-  G. Xiong, Q. Jin, Z. Lu, and A. Zhang.  
**Benchmarking retrieval-augmented generation for medicine, 2024.**

 A. Yang, A. Li, B. Yang, B. Zhang, B. Hui, B. Zheng, B. Yu, C. Gao, C. Huang, C. Lv, C. Zheng, D. Liu, F. Zhou, F. Huang, F. Hu, H. Ge, H. Wei, H. Lin, J. Tang, J. Yang, J. Tu, J. Zhang, J. Yang, J. Yang, J. Zhou, J. Zhou, J. Lin, K. Dang, K. Bao, K. Yang, L. Yu, L. Deng, M. Li, M. Xue, M. Li, P. Zhang, P. Wang, Q. Zhu, R. Men, R. Gao, S. Liu, S. Luo, T. Li, T. Tang, W. Yin, X. Ren, X. Wang, X. Zhang, X. Ren, Y. Fan, Y. Su, Y. Zhang, Y. Zhang, Y. Wan, Y. Liu, Z. Wang, Z. Cui, Z. Zhang, Z. Zhou, and Z. Qiu.

**Qwen3 technical report, 2025.**

 H. Zhou, F. Liu, B. Gu, X. Zou, J. Huang, J. Wu, Y. Li, S. S. Chen, P. Zhou, J. Liu, Y. Hua, C. Mao, C. You, X. Wu, Y. Zheng, L. Clifton, Z. Li, J. Luo, and D. A. Clifton.

**A survey of large language models in medicine : Progress, application, and challenge, 2024.**