

Med-KAG, une approche de génération augmentée par connaissances : analyse des performances et limites de la récupération par embedding

Edouard Haddag, Gabriel H.A. Medeiros & Lina F. Soualmia

2 juillet 2026

Université de Rouen Normandie

Laboratoire d'Informatique, du Traitement de l'Information et des Systèmes (LITIS)



AfIA

Association française
pour l'Intelligence Artificielle



Motivation : Hallucinations en Médecine

- **Potentiel des LLM** : Analyse des dossiers de santé (électroniques) (ALGHAMDI et MOSTAFA 2025).



Motivation : Hallucinations en Médecine

- **Potentiel des LLM** : Analyse des dossiers de santé (électroniques) (ALGHAMDI et MOSTAFA 2025).
- **Manque de fiabilité** : Risque de générer des données cliniques factuellement incorrectes.



Motivation : Hallucinations en Médecine

- **Potentiel des LLM** : Analyse des dossiers de santé (électroniques) (ALGHAMDI et MOSTAFA 2025).
- **Manque de fiabilité** : Risque de générer des données cliniques factuellement incorrectes.
- **Raisonnement en boîte noire** : Difficulté d'auditer la source des affirmations médicales.




Motivation : Hallucinations en Médecine

- **Potentiel des LLM** : Analyse des dossiers de santé (électroniques) (ALGHAMDI et MOSTAFA 2025).
- **Manque de fiabilité** : Risque de générer des données cliniques factuellement incorrectes.
- **Raisonnement en boîte noire** : Difficulté d'auditer la source des affirmations médicales.
- **Intégration clinique** : Les cliniciens exigent des outils transparents et dignes de confiance.



Le RAG en médecine une solution possible ?

Définition : Native RAG



- **MedRAG (XIONG et al. 2024/08)** : Précision de 39.6%→ 70.6% sur PubMedQA avec GPT-4


- **MedRAG (XIONG et al. 2024/08)** : Précision de 39.6%→ 70.6% sur PubMedQA avec GPT-4
- **HASSAN et al. 2025** : Précision de 55.4%→ 71.8% sur PubMedQA avec Llama 2

- **Contradictions** : Possibilité de conflits entre les documents récupérés.

- **Contradictions** : Possibilité de conflits entre les documents récupérés.
- **Redondance** : Duplication de l'information dans l'index.

- **Contradictions** : Possibilité de conflits entre les documents récupérés.
- **Redondance** : Duplication de l'information dans l'index.
- **Perte de liens** : Pas de conservation sémantique explicite entre les chunks.

Solution & Définition : GraphRAG (KAG)




- **MedGraphRAG (Wu et al. 2025/07)** : Précision de 75.3%→ 83.3% sur PubMedQA avec GPT-4

- **MedGraphRAG (Wu et al. 2025/07)** : Précision de 75.3%→ 83.3% sur PubMedQA avec GPT-4
- **MedSumGraph (KIM, Yoo et JEONG 2026)** : Précision de 61.40%→ 84.20% sur PubMedQA avec Llama 3 (70b)

Med-KAG : Un KAG médical avec récupération par embedding


L'UMLS en Graphe de Connaissance

- **Extraction** : Analyse des fichiers RRF (MRCONSO, MRREL) issus du métathésaurus UMLS.




L'UMLS en Graphe de Connaissance

- **Extraction** : Analyse des fichiers RRF (MRCONSO, MRREL) issus du métathésaurus UMLS.
- **Filtrage** : Sélection des concepts pertinents (CUI) et des relations (REL/RELA).




L'UMLS en Graphe de Connaissance

- **Extraction** : Analyse des fichiers RRF (MRCONSO, MRREL) issus du métathésaurus UMLS.
- **Filtrage** : Sélection des concepts pertinents (CUI) et des relations (REL/RELA).
- **Modélisation** : Conversion vers une base de données orientée graphe (Neo4j).




L'UMLS en Graphe de Connaissance

- **Extraction** : Analyse des fichiers RRF (MRCONSO, MRREL) issus du métathésaurus UMLS.
- **Filtrage** : Sélection des concepts pertinents (CUI) et des relations (REL/RELA).
- **Modélisation** : Conversion vers une base de données orientée graphe (Neo4j).
- **Statistique** : Plus de 13 millions de nœuds et 50 millions de relations interconnectées.



Notre architecture



Mécanisme de récupération


```
CREATE VECTOR INDEX umls_index IF NOT EXISTS
FOR (c:UMLSConcept) ON (c.embedding)
OPTIONS {
  indexConfig: {
    `vector.dimensions`: 768,
    `vector.similarity_function`: 'cosine'
  }
};
```

Mécanisme de récupération

```
CREATE VECTOR INDEX umls_index IF NOT EXISTS
FOR (c:UMLSConcept) ON (c.embedding)
OPTIONS {
  indexConfig: {
    `vector.dimensions`: 768,
    `vector.similarity_function`: 'cosine'
  }
};

CALL db.index.vector.queryNodes(
  'umls_index', $top_k, $embedding
)
YIELD node
MATCH p = (node)-[*0..$neighborhood]-(neighbor)
RETURN p;
```

Exemple de sous-graphe récupéré



L'évaluation de Med-KAG sur PubMedQA

Question : Spinal subdural hematoma : a sequela of a ruptured intracranial aneurysm ?

Options :

- **A** yes
- **B** no
- **C** maybe

Note : PubMedQA contient 500 questions, toutes avec trois réponses possibles.

- **RAG** : Le modèle augmenté par notre module de récupération.

- **RAG** : Le modèle augmenté par notre module de récupération.
- **RAG-Cleaner** : Le modèle n'est pas contraint par un format de réponse strict lors de la génération. Un modèle tiers intervient a posteriori pour formater la réponse.

- **RAG** : Le modèle augmenté par notre module de récupération.
- **RAG-Cleaner** : Le modèle n'est pas contraint par un format de réponse strict lors de la génération. Un modèle tiers intervient a posteriori pour formater la réponse.
- **RAG-Sum-Cleaner** : Le sous-graphe récupéré est converti en langage naturel par un modèle intermédiaire.

Métriques sur les différentes variations de Med-KAG

Modèle	Précision	Temps (s)
Native (Qwen3-1.7B)	49,00% (245/500)	15,04
Native (Qwen3-4B)	51,60% (258/500)	108,33
RAG (Qwen3-1.7B)	39,60% (198/500)	76,21
RAG (Qwen3-4B)	37,40% (187/500)	325,18
RAG-Cleaner (Qwen3-1.7B)	46,00% (230/500)	94,23
RAG-Sum-Cleaner (Qwen3-1.7B)	37,00% (185/500)	178,27

Métriques sur les différentes variations de Med-KAG

Modèle	Précision	Temps (s)
Native (Qwen3-1.7B)	49,00% (245/500)	15,04
Native (Qwen3-4B)	51,60% (258/500)	108,33
RAG (Qwen3-1.7B)	39,60% (198/500)	76,21
RAG (Qwen3-4B)	37,40% (187/500)	325,18
RAG-Cleaner (Qwen3-1.7B)	46,00% (230/500)	94,23
RAG-Sum-Cleaner (Qwen3-1.7B)	37,00% (185/500)	178,27

Métrique (RAG)	Moyenne	Médiane	Écart Type
Nœuds récupérés	102.55	83,00	73.33
Arêtes récupérées	228.74	185,00	160.61

Table 1: top_k = 5 et neighborhood = 1

Pourquoi les performances sont-elles inférieures?

- **Graphe très dense** : Malgré un top-k et un voisinage faibles, les sous-graphes récupérés restent volumineux.

Pourquoi les performances sont-elles inférieures?

- **Graphe très dense** : Malgré un top-k et un voisinage faibles, les sous-graphes récupérés restent volumineux.
- **Lost in the middle (Liu et al. 2024)** : Noyé dans un contexte trop long, le modèle de langue manque l'information pertinente.

Pourquoi les performances sont-elles inférieures?

- **Graphe très dense** : Malgré un top-k et un voisinage faibles, les sous-graphes récupérés restent volumineux.
- **Lost in the middle (Liu et al. 2024)** : Noyé dans un contexte trop long, le modèle de langue manque l'information pertinente.
- **UMLS insuffisant** : À lui seul, il ne suffit pas à l'aide à la décision, ses relations sémantiques sont peu adaptées au raisonnement diagnostique.

Pourquoi les performances sont-elles inférieures?

- **Graphe très dense** : Malgré un top-k et un voisinage faibles, les sous-graphes récupérés restent volumineux.
- **Lost in the middle (Liu et al. 2024)** : Noyé dans un contexte trop long, le modèle de langue manque l'information pertinente.
- **UMLS insuffisant** : À lui seul, il ne suffit pas à l'aide à la décision, ses relations sémantiques sont peu adaptées au raisonnement diagnostique.
- **Modèles de petite taille** : Pénalisent la précision, mais nécessaires pour une exécution locale.

- **L'optimisation technique** : La transition vers une génération de requêtes Text-to-Cypher guidée par LLM.

- **L'optimisation technique** : La transition vers une génération de requêtes Text-to-Cypher guidée par LLM.
- **L'extension de l'évaluation** : La validation du système sur d'autres jeux de données biomédicaux et sur plusieurs familles de LLM open-source.

- **L'optimisation technique** : La transition vers une génération de requêtes Text-to-Cypher guidée par LLM.
- **L'extension de l'évaluation** : La validation du système sur d'autres jeux de données biomédicaux et sur plusieurs familles de LLM open-source.
- **La mesure de la fiabilité** : L'intégration de métriques explicitement conçues pour quantifier la réduction des hallucinations.


- **L'optimisation technique** : La transition vers une génération de requêtes Text-to-Cypher guidée par LLM.
- **L'extension de l'évaluation** : La validation du système sur d'autres jeux de données biomédicaux et sur plusieurs familles de LLM open-source.
- **La mesure de la fiabilité** : L'intégration de métriques explicitement conçues pour quantifier la réduction des hallucinations.
- **L'application clinique** : la validation sur des données cliniques réelles issues d'entrepôts de données de santé.

Merci de votre attention!

Des questions?

contact@c2fc2f.com

<https://github.com/c2fc2f/Med-KAG/tree/0.2.0>



-  ALGHAMDI, H. et A. MOSTAFA. « **Advancing EHR analysis : Predictive medication modeling using LLMs** ». In : *Information Systems* 131 (2025), p. 102528. URL : <https://www.sciencedirect.com/science/article/pii/S0306437925000134>.
-  HASSAN, T., M. F. KARIM, H. JEELANI, E. BEHNAM, R. GREEN et F. J. SYED. ***Optimizing Medical Question-Answering Systems : A Comparative Study of Fine-Tuned and Zero-Shot Large Language Models with RAG Framework***. 2025. arXiv : 2512.05863 [cs.CL]. URL : <https://arxiv.org/abs/2512.05863>.
-  KIM, D., S. YOO et O. JEONG. « **MedSumGraph : enhancing GraphRAG for medical QA with summarization and optimized prompts** ». In : *Artificial Intelligence in Medicine* 172 (2026), p. 103311. URL : <https://www.sciencedirect.com/science/article/pii/S0933365725002465>.

-  LIU, N. F., K. LIN, J. HEWITT, A. PARANJAPPE, M. BEVILACQUA, F. PETRONI et P. LIANG. « **Lost in the Middle : How Language Models Use Long Contexts** ». In : *Transactions of the Association for Computational Linguistics* 12 (2024), p. 157-173. URL : <https://aclanthology.org/2024.tacl-1.9/>.
-  WU, J., J. ZHU, Y. QI, J. CHEN, M. XU, F. MENOLASCINA, Y. JIN et V. GRAU. « **Medical Graph RAG : Evidence-based Medical Large Language Model via Graph Retrieval-Augmented Generation** ». In : *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1 : Long Papers)*. Sous la dir. de W. CHE, J. NABENDE, E. SHUTOVA et M. T. PILEHVAR. Vienna, Austria : Association for Computational Linguistics, 2025/07, p. 28443-28467. URL : <https://aclanthology.org/2025.acl-long.1381/>.
-  XIONG, G., Q. JIN, Z. LU et A. ZHANG. « **Benchmarking Retrieval-Augmented Generation for Medicine** ». In : *Findings of the Association for Computational Linguistics : ACL 2024* (2024/08). Sous la dir. de L.-W. KU, A. MARTINS et V. SRIKUMAR, p. 6233-6251. URL : <https://aclanthology.org/2024.findings-acl.372/>.